

**PROJECT UJIAN AKHIR SEMESTER
METODE PERAMALAN**

**Analisis Peramalan Jumlah Permintaan Produk Toko
dengan Metode SARIMA dan Prophet**



Anggota Kelompok : 1. Gabriella Yoanda Pelawi (22/493047/PA/21159)
2. Meila Dwi Nurini (22/497250/PA/21408)
3. Mahardi Nalendra Syafa (22/502515/PA/21558)

Dosen Pengampu : Mohamad Fahruli Wahyujati, S.Si., M.Si.

**PROGRAM STUDI SARJANA STATISTIKA
DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS GADJAH MADA**

2024

Abstrak

Analisis ini bertujuan untuk meramalkan permintaan produk toko menggunakan metode SARIMA dan Prophet. Data yang digunakan berasal dari kompetisi Store Item Demand Forecasting Challenge di Kaggle, yang terdiri dari lima tahun data penjualan item toko. Item 28 dipilih untuk analisis karena memiliki volume penjualan yang signifikan dan pola musiman yang jelas. Proses eksplorasi data awal (EDA) menunjukkan adanya tren naik dan pola musiman yang stabil, dengan satu kali differencing ($d=1$) cukup untuk mencapai stasionaritas. Model SARIMA dioptimalkan menggunakan fungsi `auto_arima`, menghasilkan dua model terbaik. Evaluasi menunjukkan bahwa model SARIMA $(0,1,6) \times (0,1,1)[7]$ lebih akurat dengan nilai MAE dan MAPE yang lebih rendah yaitu 6,285 dan 0,213.

Selain itu, metode Prophet digunakan dengan mempertimbangkan variabel tambahan seperti hari libur dan tren musiman. Hasil peramalan menunjukkan bahwa metode Prophet memberikan akurasi yang lebih tinggi dibandingkan dengan model SARIMA. Indikator perbandingan utama antara kedua metode ini adalah Mean Absolute Error (MAE) dan Mean Absolute Percentage Error (MAPE), yang menunjukkan bahwa Prophet memiliki nilai kesalahan yang lebih rendah dan akurasi yang lebih tinggi. Model Prophet terbaik, menghasilkan MAPE sebesar 0,168 dan MAE sebesar 4,250. Kesimpulannya, metode Prophet terbukti lebih efektif dalam memprediksi permintaan produk toko, sehingga dapat membantu pengelola toko dalam pengambilan keputusan terkait manajemen persediaan dan strategi penjualan.

LATAR BELAKANG

Di era persaingan ketat industri ritel global, perusahaan beralih ke big data dan analitik prediktif untuk merancang strategi yang efektif dalam meningkatkan keuntungan (Eric T. Bradlow, 2017) Strategi *supply chain* yang efisien sangat penting untuk merampingkan operasi bisnis, meningkatkan efisiensi, memperbaiki manajemen hubungan pelanggan, dan menjaga keberlanjutan di pasar. Salah satu elemen kunci dalam *Supply Chain Management* (SCM) adalah manajemen inventaris, yang mencakup pemantauan stok, jumlah barang yang akan dijual, pembelian dari pelanggan dan pemasok, serta pemenuhan pesanan. (Deepesh Singh, 2018)

Manajemen inventaris sering menghadapi dua masalah utama yaitu *Out-of-Stock* dan *Overstock*. Kehabisan stok mengacu pada kurangnya ketersediaan produk yang dapat menyebabkan penurunan layanan pelanggan dan potensi kehilangan pelanggan ke pesaing. Sebaliknya, kelebihan stok dapat meningkatkan biaya keuangan dan tenaga kerja, mengurangi ruang di gudang, serta menurunkan kualitas produk, yang semuanya dapat menyebabkan kerugian tambahan. Oleh karena itu, penting untuk memiliki prosedur kontrol inventaris yang terdefinisi dengan baik untuk mengatasi masalah ini, meningkatkan efisiensi operasi, dan menghilangkan pemborosan investasi inventaris. (Taha Falatouri, 2022)

Solusi peramalan permintaan sangat penting untuk mendukung berbagai proses pengambilan keputusan manajemen inventaris di ritel. Banyak peritel, terutama bisnis e-commerce, telah meningkatkan investasi mereka dalam peramalan permintaan untuk meningkatkan kinerja dan akurasi stok mereka. Strategi peramalan permintaan yang efektif sangat penting untuk kesuksesan peritel, karena dapat meningkatkan tingkat layanan pelanggan dan menurunkan biaya terkait ketidaksesuaian pasokan-permintaan (Jakob Huber, 2020). Dengan menggabungkan berbagai data seperti riwayat penjualan dan penjualan musiman, serta menerapkan analisis prediktif, pengecer dapat meningkatkan akurasi perkiraan stok mereka.

Penelitian ini menggunakan pendekatan peramalan deret waktu yaitu SARIMA, untuk mempelajari pola dalam data historis dan memberikan ramalan permintaan di masa depan. Selain itu, pendekatan pembelajaran mesin seperti Facebook Prophet juga digunakan. Pendekatan pembelajaran mesin ini telah terbukti memberikan prediksi yang lebih akurat dibandingkan dengan metode lainnya, menjadikannya alat yang berharga dalam merencanakan dan mengelola inventaris mereka dengan lebih efektif.

METODE PENELITIAN


Dataset

Data yang digunakan dalam analisis ini berasal dari kompetisi Store Item Demand Forecasting Challenge di Kaggle. Dataset ini terdiri dari lima tahun data penjualan item toko yang terbagi menjadi dua set: dataset pelatihan dan dataset uji. Dari dataset akan dilakukan analisis untuk meramalkan penjualan selama tiga bulan untuk 50 item yang berbeda di 10 toko yang berbeda menggunakan riwayat penjualan selama lima tahun. Dalam penelitian ini, data item 28 dari toko digunakan sebagai fokus analisis untuk menerapkan metode peramalan SARIMA dan Prophet.

Metode SARIMA

Analisis dengan metode SARIMA dilakukan dengan pendekatan kuantitatif dengan desain eksploratif untuk menganalisis dan mengevaluasi penerapan model SARIMA (*Seasonal Autoregressive Integrated Moving Average*) dalam peramalan jumlah permintaan produk di sebuah toko. Model SARIMA mampu memodelkan analisis dan peramalan jumlah permintaan produk di toko yang memiliki pola musiman. Data deret waktu (time series) dianalisis menggunakan metode SARIMA untuk memahami pola musiman dan mengevaluasi kinerja model tersebut dalam melakukan peramalan. Model SARIMA dinyatakan sebagai SARIMA(p, d, q)(P, D, Q)[s], dengan parameter : p merupakan orde autoregresif non-musiman, d adalah derajat differencing non-musiman, q adalah orde moving average non-musiman, P adalah orde autoregresif musiman, D adalah derajat differencing musiman, Q adalah orde moving average musiman, dan s merupakan panjang siklus musiman (Luo, et al., 2022).

Bentuk model SARIMA pada gambar (1) sebagai berikut: (Muhtar, Ningrum, & H, 2023):



Gambar 1, Model SARIMA

Tahapan analisis meliputi pengumpulan data, pra-pemrosesan data (pengonversian kolom menjadi tipe datetime, membersihkan anomali dan outlier, serta visualisasi untuk identifikasi pola musiman dan tren), uji stasionaritas menggunakan uji Dickey-Fuller (ADF),

dan differencing untuk membuat data stasioner jika diperlukan. Plot Autocorrelation Function (ACF) dan Partial Autocorrelation Function (PACF) digunakan untuk mengidentifikasi komponen AR dan MA.

Model SARIMA kemudian diestimasi menggunakan Maximum Likelihood Estimation (MLE). Evaluasi model dilakukan menggunakan metrik Mean Absolute Error (MAE) dan pemeriksaan diagnostik residual untuk memastikan residual model berperilaku seperti white noise. Model terbaik dipilih menggunakan nilai Akaike Information Criterion (AIC) atau Bayesian Information Criterion (BIC). Setelah evaluasi, model SARIMA digunakan untuk prakiraan jumlah permintaan produk di masa depan, yang hasilnya dibandingkan dengan data aktual untuk mengevaluasi akurasi model. Peramalan ini membantu pengelola toko dalam membuat keputusan yang lebih baik berdasarkan informasi yang akurat tentang permintaan produk di masa depan.

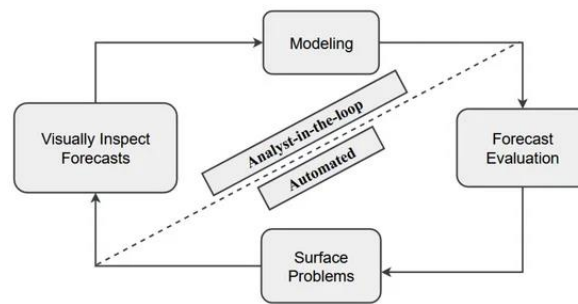
Prophet

Prophet adalah algoritma yang dikembangkan oleh Meta Facebook yang dapat melihat frekuensi, pola, pengaruh musiman, dan properti deret waktu lainnya (Yuanjiang Li, 2021). Prophet model menerapkan model adaptif umum atau General Adaptive Model (GAM) untuk memenuhi fungsi pemulusan (smoothing) dan peramalan. Prophet model merupakan analisis ramalan deret waktu berdasarkan persamaan linier sederhana yang mengakomodasi tren non-linear dengan menambahkan musiman harian, mingguan, dan tahunan dengan memperhitungkan efek hari libur. Prophet dirumuskan pada persamaan di bawah ini:

$$y(t) = g(t) + s(t) + h(t) + \xi$$

Dalam algoritma Prophet, $g(t)$ merupakan fungsi tren yang mengambil data non-periodik dalam analisis deret waktu sedangkan, dalam persamaan $s(t)$ adalah perubahan periodik dalam mingguan atau tahunan. Dalam fungsi yang diberikan, $h(t)$ mengambil anomali statistik yang terjadi karena kesempatan dan penjualan promosi dapat juga berupa hari libur nasional. Fungsi $h(t)$ berdistribusi normal yang mengurangi fluktuasi yang tidak terduga dan acak. Sedangkan ξ , adalah istilah kesalahan (error term) untuk setiap perubahan yang tidak dapat diakomodasi oleh model.

Algoritma Prophet termasuk dalam metode peramalan yang memerlukan pembagian tugas antara manusia dan otomatisasi. Gambar (2) merepresentasikan alur dari pemodelan prophet.




Gambar 2; Proses Metode Prophet

Dalam proses peramalan dengan metode prophet, peramalan data deret waktu awalnya dihasilkan menggunakan berbagai parameter dan spesifikasi yang memiliki interpretasi langsung oleh manusia. Setelah itu, kinerja peramalan dievaluasi dalam model, dan jika muncul masalah (misalnya, kinerja yang buruk), model akan memberi tahu bahwa diperlukan intervensi dari manusia. Selanjutnya model dapat disesuaikan dengan tepat berdasarkan umpan balik tersebut.

HASIL DAN ANALISIS

Proses eksplorasi data awal (EDA) dilakukan untuk memahami karakteristik dasar dari dataset yang digunakan. Terdapat 10 toko pada dataset dengan masing-masing 50 item jenis barang yang dijual. Berdasarkan jumlah penjualan yang dimiliki, toko dengan penjualan terbanyak adalah "Store 2" dengan total sales 6120128. Berdasarkan analisis yang dilakukan pada "Store 2", item dengan penjualan terbanyak adalah "item 28", dengan total sales 205677.



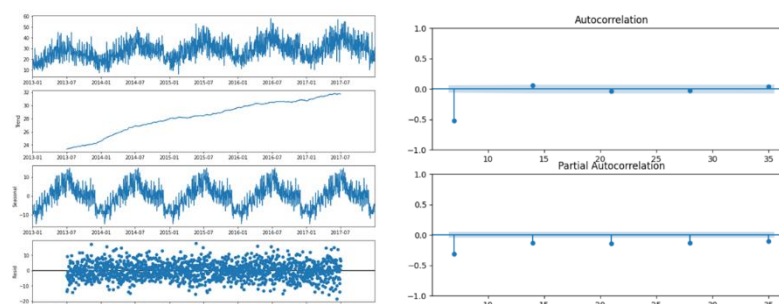
Gambar 3; Sebaran Data

Data yang digunakan dalam analisis adalah data permintaan item 28 dari tahun 2013 hingga 2017. Tujuan dari analisis adalah untuk meramalkan permintaan penjualan toko dari Januari 2018 hingga Maret 2018 menggunakan analisis peramalan SARIMA dan Prophet.

SARIMA

Proses eksplorasi data awal (EDA) dilakukan untuk memahami karakteristik dasar dari data penjualan item 28. Visualisasi data permintaan menunjukkan adanya pola tren naik yang mengindikasikan bahwa permintaan meningkat seiring waktu. Selain itu, terdapat komponen musiman yang menunjukkan permintaan rendah pada bulan Januari dan meningkat hingga mencapai puncaknya di bulan Juni. Pola musiman ini bersifat aditif karena pola komponen musimannya konstan selama periode waktu tertentu.

Hasil uji stasionaritas menunjukkan bahwa satu kali differencing ($d=1$) cukup untuk membuat data deret waktu menjadi stasioner, memenuhi kriteria uji Augmented Dickey-Fuller (ADF) dan Kwiatkowski-Phillips-Schmidt-Shin (KPSS). Oleh karena itu, parameter differencing (d) untuk model SARIMA ditetapkan sebagai 1, memastikan data siap untuk pemodelan yang akurat. Plot Autocorrelation Function (ACF) dan Partial Autocorrelation Function (PACF) digunakan untuk mengidentifikasi komponen autoregressive (AR) dan moving average (MA) yang optimal. Plot ACF menunjukkan adanya pola musiman dengan puncak signifikan pada lag 7, yang mengindikasikan siklus mingguan dalam data penjualan. Setelah differencing dilakukan untuk mencapai stasionaritas, plot ACF dan PACF tidak menunjukkan autokorelasi signifikan, membuktikan bahwa data telah menjadi stasioner.



Gambar 4; Plot ACF PAC & Komposisi

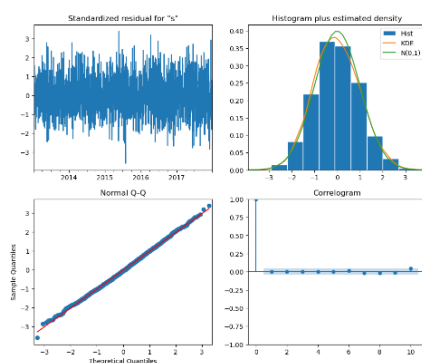
Dalam proses pemilihan model SARIMA yang tepat, dilakukan analisis menggunakan `auto_arima` untuk menemukan model terbaik berdasarkan metrik *Akaike Information Criterion* (AIC) dan *Bayesian Information Criterion* (BIC). Fungsi `auto_arima` digunakan untuk mengidentifikasi parameter terbaik dengan memeriksa berbagai kombinasi parameter (p, d, q) dan (P, D, Q) untuk model musiman. Model yang dihasilkan dari proses ini kemudian dievaluasi berdasarkan nilai AIC dan BIC untuk memastikan pemilihan model yang optimal. Dari analisis ini, dua model SARIMA terbaik yang diperoleh adalah SARIMA $(0,1,6) \times (0,1,1)[7]$ dan SARIMA $(6,1,1) \times (6,1,0)[7]$.

Metriks	SARIMA(0,1,6)x(0,1,1)[7]	SARIMA (6,1,1)x(6,1,0)[7]
AIC	11485.804	11680.726
BIC	11529.848	117.803
Prob(Q)	0.97	1.00
Prob(JB)	0.13	0.98


Tabel 1; Metriks SARIMA

Model SARIMA (0,1,6)x(0,1,1)[7] memiliki nilai AIC sebesar 12085.632 dan nilai BIC sebesar 12102.160. Sementara itu, model SARIMA (6,1,1)x(6,1,0)[7] memiliki nilai AIC sebesar 12075.123 dan nilai BIC sebesar 12092.567. Nilai AIC dan BIC yang lebih rendah menunjukkan bahwa model tersebut memiliki keseimbangan terbaik antara kecocokan model dan kompleksitas. Untuk menentukan model terbaiknya, akan dilakukan *diagnostic checking*.

Model SARIMA (0,1,6)x(0,1,1)[7] memiliki nilai Prob(Q) = 0.97 dan Prob(JB) = 0.13. Sementara itu, Model SARIMA (6,1,1)x(6,1,0)[7] memiliki nilai Prob(Q) = 1.00 dan Prob(JB) = 0.98. Prob(Q) digunakan untuk mengetahui ada tidaknya korelasi dari residual, dengan H0 adalah residual tidak berkorelasi. Prob(JB) digunakan untuk mengevaluasi distribusi normalitas dari residual, dengan H0 yang menyatakan bahwa residual berdistribusi normal. Jika Prob(Q) dari kedua model lebih besar dari 0.05, maka H0 tidak ditolak, menunjukkan bahwa residual keduanya tidak berkorelasi. Selanjutnya, jika Prob(JB) dari kedua model juga lebih besar dari 0.05, maka H0 tidak ditolak, menunjukkan bahwa residual keduanya berdistribusi normal



Gambar 5; Plot Model SARIMA (0,1,6) x (0,1,1)[7]



Gambar 6; Plot Model SARIMA (6,1,1)x(6,1,0)[7]

Berdasarkan plot yang dihasilkan dari kedua model SARIMA, dapat disimpulkan beberapa hal. Untuk model SARIMA (0,1,6)x(0,1,1)[7], residual terstandarisasi tidak menunjukkan adanya pola tertentu, mengindikasikan bahwa model yang digunakan cukup baik. Histogram dan estimasi kernel density (kde) menunjukkan bahwa kurva oranye mirip dengan kurva hijau. Pada plot ACF, 95% korelasi untuk lag di atas satu tidak signifikan dan

berada dalam area biru, menunjukkan model yang baik. Plot Normal Q-Q menunjukkan bahwa sebagian besar (sekitar 95%) titik data berada pada garis lurus kecuali beberapa titik ekstrem, mengindikasikan distribusi normal dari residual.

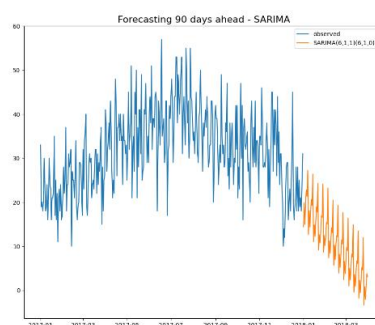
Sebaliknya, untuk model SARIMA (6,1,1)x(6,1,0)[7], residual terstandarisasi juga tidak menunjukkan pola tertentu, mengindikasikan model yang baik. Namun, histogram dan estimasi KDE menunjukkan distribusi normal, tetapi kurva oranye tidak terlalu mirip dengan kurva hijau. Pada plot ACF, 95% korelasi untuk lag di atas satu tidak signifikan dan berada dalam area biru, juga menunjukkan model yang baik. Plot Normal Q-Q menunjukkan bahwa sebagian besar titik data berada pada garis lurus, mengindikasikan distribusi normal dari residual.

Berdasarkan *diagnostic checking* di atas dapat disimpulkan bahwa semua model baik, maka akan dibandingkan dengan metrik MAE dan MAPE nya sebagai berikut.

Metriks	SARIMA (0,1,6)x(0,1,1)[7]	SARIMA (6,1,1)x(6,1,0)[7]
MAE	6,910	6,285
MAPE	0,301	0,213

Tabel 2; Metriks SARIMA

Dari Tabel perbandingan tersebut, terlihat bahwa SARIMA (6,1,1)x(6,1,0)[7] merupakan model yang terbaik untuk melakukan peramalan jumlah permintaan toko.



Gambar 7; Peramalan dengan SARIMA

Berdasarkan gambar plot terlihat bahwa jumlah permintaan selama 3 bulan kedepan hasil *forecasting* mengalami penurunan, artinya nanti selama 3 bulan pertama tahun 2018, permintaan barang di toko 2 dalam item 28 mengalami penurunan permintaan.


Dalam model SARIMA, kita belum mempertimbangkan faktor lain dalam jumlah permintaan barang ini seperti hari libur. Oleh karena itu, kami mencoba juga melakukan

peramalan dengan mempertimbangkan hari libur sebagai data eksternal. Metode yang akan digunakan untuk peramalan adalah Prophet. Selanjutnya, kami akan membandingkan hasilnya.

Prophet


Dalam penelitian ini, tiga model Prophet digunakan untuk menganalisis peramalan permintaan produk toko. Model pertama menggunakan fitting dengan mode seasonal additive untuk menangkap perubahan tren dan musim dalam data. Model kedua menyesuaikan hyperparameter untuk fleksibilitas tren dan perubahan musim dengan lebih akurat, dengan mengatur skala prior changepoint dan seasonality..


Model ketiga dalam penelitian ini meningkatkan hasil dari model sebelumnya dengan memasukkan argumen hari libur di Amerika Serikat seperti New Year's, Martin Luther King Jr. Day, Washington's Birthday, Memorial Day, Independence Day, Labor Day, Columbus Day, Veterans Day, Thanksgiving, dan Christmas. Tujuannya adalah agar model dapat lebih akurat dalam menangkap perubahan tren dan musim yang terjadi selama hari libur, sehingga peramalan permintaan produk menjadi lebih relevan dan akurat untuk membantu pengelolaan stok dan pemenuhan permintaan konsumen..



Gambar 8; Hasil Pemodelan Prophet


Setelah menyesuaikan model dan membuat prediksi, Prophet menghasilkan tabel hasil yang mencakup yhat (nilai prediksi aktual), serta yhat_lower dan yhat_upper untuk tingkat ketidakpastian. Grafik menunjukkan titik-titik hitam sebagai data deret waktu aktual, garis biru sebagai ramalan model, dan area biru di bawahnya sebagai tingkat ketidakpastian yang dibatasi oleh nilai prediksi yhat_lower dan yhat_upper.





Gambar 9; Analisis Komponen

Dari analisis komponen ramalan tersebut, beberapa wawasan dapat diperoleh. Pertama, tren menunjukkan peningkatan penjualan dari waktu ke waktu. Kedua, musiman mingguan menunjukkan peningkatan penjualan akhir pekan dengan penurunan pada hari Senin, yang dipengaruhi oleh hari libur. Ketiga, musiman tahunan menunjukkan penjualan tertinggi pada bulan Juli dan terendah pada Januari, yang mungkin terkait dengan penjualan musiman dengan diskon. Memahami komponen ini penting untuk meningkatkan model, dengan memasukkan hari libur, acara khusus, dan musiman untuk ramalan yang lebih akurat dan informatif..



Gambar 10; Hasil peramalan 3 model prophet 1-3

Gambar (10) mengilustrasikan hasil peramalan penjualan dari ketiga model ini dalam format yang memudahkan perbandingan dengan grafik lain dalam penelitian ini. Berdasarkan gambar-gambar ini, semua model telah berhasil menangkap pola musiman dalam penjualan. Namun, model Prophet yang telah disempurnakan dalam model kedua menunjukkan peningkatan signifikan dengan RMSE yang turun dari 194,93 menjadi 167,29, menunjukkan peningkatan dalam akurasi peramalan. Model ketiga menunjukkan diagnostik yang paling baik, seperti yang tercatat dalam tabel. Metode ini telah mengungguli model-model sebelumnya, yaitu SARIMA.

Metriks	Model Prophet 1	Model Prophet 2	Model Prophet 3
MAE	4.275	4.268	4.250
MAPE	0.169	0.168	0.168

Tabel 3; Metriks Prophet

KESIMPULAN

Pada penelitian ini, telah dilakukan peramalan jumlah permintaan toko selama tiga bulan ke depan dengan menggunakan model SARIMA dan Prophet. Data permintaan toko yang dianalisis memiliki pola musiman, sehingga model SARIMA dipilih sebagai metode awal peramalan. Dua model SARIMA terbaik yang diidentifikasi adalah SARIMA $(0,1,6) \times (0,1,1)[7]$ dan SARIMA $(6,1,1) \times (6,1,0)[7]$.

Setelah dilakukan diagnostic checking, SARIMA $(6,1,1) \times (6,1,0)[7]$ terpilih sebagai model terbaik karena memiliki nilai Mean Absolute Percentage Error (MAPE) dan Mean Absolute Error (MAE) yang lebih rendah dibandingkan SARIMA $(0,1,6) \times (0,1,1)[7]$. Hasil peramalan dengan model SARIMA menunjukkan tren penurunan jumlah permintaan selama tiga bulan ke depan.

Selanjutnya, untuk mempertimbangkan faktor hari libur yang dapat memengaruhi jumlah permintaan, digunakan model peramalan Prophet. Tiga metode peramalan dari Prophet diuji, dan hasilnya menunjukkan bahwa model Prophet lebih baik dibandingkan model SARIMA sebelumnya. Model Prophet terbaik, yaitu Model Prophet 3, menghasilkan MAPE sebesar 0,168 dan MAE sebesar 4,250.

Dengan demikian, berdasarkan hasil penelitian ini, model Prophet terbukti lebih efektif dalam memprediksi jumlah permintaan barang di toko selama tiga bulan ke depan, terutama dengan mempertimbangkan variabel tambahan seperti hari libur.

SARAN

Toko disarankan untuk mengelola stok berdasarkan prediksi penurunan permintaan selama tiga bulan ke depan. Fokus pada produk yang populer dengan mengurangi pemesanan barang yang diprediksi turun adalah strategi yang direkomendasikan. Selain itu, toko dapat menggunakan promosi dan diskon untuk menarik pelanggan selama periode penurunan, serta memanfaatkan hari libur untuk meningkatkan penjualan dengan promosi khusus atau acara menarik.

Referensi

- Deepesh Singh, A. V. (2018). Inventory Management in Supply Chain. *ICMPC* , 3867-3872.
- Eric T. Bradlow, M. G. (2017). The Role of Big Data and Predictive Analytics in Retailing. *Journal of Retailing*, 79-95.
- Jakob Huber, H. S. (2020). Daily retail demand forecasting using machine learning with emphasis on calendric special days. *International Journal of Forecasting*, 1420-1438.
- Luo, Z., Jia, X., Bao, J., Song, Z., Zhu, H., Liu, M., . . . Shi, X. (2022). A Combined Model of SARIMA and Prophet Models in Forecasting AIDS Incidence in Henan Province, China. *International Journal of Environmental Research and Public Health*, 3.
- Muhtar, A., Ningrum, D. C., & H, R. M. (2023). Penerapan Time Series Forecasting untuk Memprediksi Pertumbuhan Ekonomi . *Data Science Indonesia*, 81.
- Taha Falatouri, F. D. (2022). Predictive Analytics for Demand Forecasting – A Comparison of SARIMA and LSTM in Retail SCM. *Procedia Computer Science*, 993-1003.
- Yuanjiang Li, Y. Y. (2021). Clothing Sale Forecasting by a Composite GRU–Prophet Model With an Attention Mechanism. *IEEE Transactions on Industrial Informatics*, 8335-8344.

LAMPIRAN

https://drive.google.com/drive/folders/1TTQUoZO0uegKKyTL_szAgglOCOLsuP5a?usp=sharing